

**Mini proyecto de Series Temporales y Pronóstico
Forecasting de concentración diaria de benceno**

Grupo 6 - Estados Unidos | Aprendizaje Automático II

Licenciatura en Ingeniería de Datos e Inteligencia Artificial

Gael Paulo y Bruno del Valle

1. Introducción y planteamiento del problema

El objetivo de este mini proyecto es construir un flujo de forecasting para estimar la concentración diaria promedio de benceno a partir de datos históricos de calidad del aire. El problema se trabaja como una serie temporal, por lo que el orden cronológico de los datos es fundamental. En este tipo de problemas no corresponde mezclar aleatoriamente observaciones pasadas y futuras, ya que eso produciría una evaluación poco realista. Por ese motivo, todo el proyecto se desarrolla respetando la secuencia temporal: primero se prepara la información, luego se divide en entrenamiento y prueba, después se entrenan los modelos y finalmente se evalúan sobre datos posteriores.

La variable temporal se construyó combinando las columnas de fecha y hora, mientras que la variable objetivo fue `concentracion_benceno`. Aunque el dataset original tenía frecuencia horaria, se decidió trabajar con frecuencia diaria, agregando los registros horarios mediante promedio. Esta transformación permite reducir el ruido horario y centrar el análisis en el comportamiento diario de la concentración de benceno. El horizonte de predicción definido fue de 7 días, por lo que los modelos buscan estimar la concentración esperada para la semana siguiente usando información histórica disponible.

2. Preparación del dataset

El archivo utilizado fue `air_quality_docente.csv`, que contiene registros de calidad del aire de una estación de monitoreo. Además de la concentración de benceno, el dataset incluye sensores de otros contaminantes y variables ambientales, como temperatura, humedad relativa y humedad absoluta. Estas variables se conservaron porque el notebook no solo desarrolla un modelo univariante, sino que también incluye una extensión con variables exógenas para comparar si la información adicional mejora la predicción.

La preparación comenzó con la carga del archivo y la creación de la columna `fecha_hora`. Luego, esta columna se convirtió en índice temporal y los datos fueron ordenados cronológicamente. La división entre entrenamiento y prueba se realizó respetando el orden de la serie: el primer 80% de los registros se usó para entrenar y el 20% final se reservó para prueba. Esta decisión es correcta porque reproduce una situación real, donde el modelo aprende del pasado y se evalúa sobre un período futuro.

Después de la partición, los datos horarios se transformaron a frecuencia diaria mediante promedio. Durante este proceso se revisó la cantidad de registros horarios por día, ya que algunos días no tenían las 24 observaciones completas. Aunque al principio se evaluó eliminar esos días, la decisión final fue conservar todos los días calendario para mantener una frecuencia diaria regular. Esta decisión es importante porque eliminar días intermedios puede romper la continuidad temporal de la serie. Por lo tanto, los días incompletos se mantienen como una limitación del dataset, pero no se eliminan.

También se revisaron valores nulos y se aplicaron tratamientos cuando fue necesario. Para las variables numéricas se utilizó interpolación temporal y completado hacia adelante y hacia atrás, especialmente en la parte del modelo con variables exógenas. Esto permitió mantener las series alineadas por fecha y evitar errores durante el entrenamiento de los modelos.

3. Análisis exploratorio

En el análisis exploratorio se estudió el comportamiento diario de la concentración de benceno. Se graficó la serie diaria junto con una media móvil de 7 días. La serie original mostró bastante variabilidad, con subidas y bajadas fuertes entre días, mientras que la media móvil ayudó a suavizar el ruido y observar mejor la tendencia general. Este comportamiento es esperable en datos ambientales, ya que la calidad del aire puede cambiar por condiciones meteorológicas, tráfico, emisiones y otros factores externos.

Las estadísticas descriptivas mostraron una media cercana a 10.68 y una mediana cercana a 10.72, por lo que el centro de la distribución está bastante equilibrado. El desvío estándar fue aproximadamente 4.24, lo que indica una dispersión relevante. El valor mínimo fue cercano a 1.43 y el máximo cercano a 24.40, mostrando que la concentración diaria de benceno puede variar bastante.

También se aplicó el criterio IQR para detectar posibles valores atípicos. Se encontraron algunos valores altos, pero no fueron eliminados. Esta decisión es adecuada porque, en un problema de calidad del aire, un valor alto puede representar un episodio real de contaminación y no necesariamente un error de medición. Eliminarlo sin justificación podría hacer que el modelo pierda información importante sobre situaciones extremas.

Además, se analizaron la ACF y la PACF para estudiar la relación entre la concentración actual y sus valores pasados. La ACF mostró dependencia en los primeros rezagos, mientras que la PACF reflejó una relación fuerte especialmente con el valor del día anterior. Esto justificó el uso de lags como variables predictoras en los modelos de forecasting.

4. Modelado univariante

El primer enfoque fue un modelo univariante, es decir, un modelo que predice la concentración de benceno utilizando únicamente valores pasados de esa misma variable. Para esto se utilizó `ForecasterRecursive` de `skforecast` junto con `RandomForestRegressor`. La estrategia recursiva convierte la serie temporal en un problema supervisado usando rezagos como variables de entrada. Para predecir varios días hacia adelante, el modelo predice primero el día siguiente y luego reutiliza esa predicción para avanzar al segundo día, repitiendo el proceso hasta completar los 7 días.

El modelo base se construyó con 7 lags, ya que la serie es diaria y el horizonte de predicción es semanal. Como regresor se usó `RandomForestRegressor` con 100 árboles y una semilla fija para asegurar reproducibilidad. En la evaluación sobre los primeros 7 días del conjunto de prueba, el modelo base obtuvo un MAE aproximado de 4.63 y un RMSE aproximado de 5.31. El MAE indica el error absoluto promedio, mientras que el RMSE penaliza más los errores grandes. Como el RMSE fue mayor que el MAE, se observa que algunos días fueron más difíciles de predecir.

Luego se realizó una evaluación más formal mediante backtesting temporal. Se usó una ventana expansiva, horizonte de 7 pasos y reentrenamiento en cada corte. Esta metodología es más apropiada que una evaluación aleatoria, porque respeta la estructura

temporal de la serie. En este backtesting, el modelo base obtuvo un MAE aproximado de 4.61 y un RMSE aproximado de 5.95. Estos valores sirvieron como referencia inicial.

Después se aplicó Grid Search para buscar una mejor configuración. Se probaron distintas cantidades de lags, específicamente 7, 14, 21 y 28, junto con varios hiperparámetros del Random Forest. La mejor configuración univariante fue un ForecasterRecursive con RandomForestRegressor, 28 lags, 100 árboles, profundidad sin limitar y min_samples_leaf igual a 3. Esta configuración obtuvo en backtesting un MAE aproximado de 4.36 y un RMSE aproximado de 5.58, mejorando al modelo base.

El mejor modelo univariante fue entrenado nuevamente y evaluado sobre los primeros 7 días del conjunto de prueba. En esa evaluación final alcanzó un MAE aproximado de 3.60 y un RMSE aproximado de 4.22. Esto muestra una mejora clara frente al modelo base. La mejora tiene sentido porque usar 28 lags permite que el modelo observe casi un mes de información pasada, capturando patrones más amplios que una ventana de solo una semana. Además, min_samples_leaf igual a 3 ayuda a reducir el riesgo de sobreajuste.

5. Modelo con variables exógenas

Como extensión del proyecto, el notebook también construyó un modelo con variables exógenas. En este caso, además de los lags de concentracion_benceno, el modelo utiliza información adicional de sensores y variables ambientales. Las variables consideradas fueron sensor_co, sensor_nmhc, sensor_nox, sensor_no2, sensor_o3, temperatura, humedad_relativa y humedad_absoluta. Esta extensión tiene sentido porque la concentración de benceno puede depender de factores externos y no solo de sus propios valores pasados.

Para usar estas variables, se generaron conjuntos exógenos diarios alineados con la serie objetivo. También se trataron valores faltantes mediante interpolación temporal y completado hacia adelante y hacia atrás. Luego se aplicó un nuevo Grid Search usando Random Forest y distintas cantidades de lags. El objetivo fue comparar si la incorporación de información ambiental mejoraba el desempeño frente al modelo univariante.

El modelo con variables exógenas es útil como comparación experimental, pero tiene una limitación operativa importante. Para predecir días futuros reales, sería necesario conocer también los valores futuros de temperatura, humedad y sensores. Si esos datos no están disponibles, el modelo exógeno no puede usarse directamente para pronosticar. Por esta razón, el notebook conserva como opción operativa principal el modelo univariante final, ya que solo necesita la historia pasada de la concentración de benceno.

6. Comparación, guardado de resultados y pronóstico final

El notebook compara el modelo base, el mejor modelo univariante y el modelo con variables exógenas usando métricas como MAE, MSE y RMSE. Esta comparación permite ordenar los modelos según su error y observar cuál tiene mejor desempeño en el horizonte de prueba. Además, se generan gráficos con las predicciones frente a los valores reales, lo que facilita interpretar visualmente los errores.

También se guardan los principales resultados del proyecto. El dataset diario procesado se guarda como `air_quality_diario_procesado.csv`. La comparación de modelos se guarda como `comparacion_modelos.csv` y la evaluación final del test de 7 días se guarda como `evaluacion_final_test_7_dias.csv`. Además, se guardan los resultados de Grid Search y los modelos entrenados con `joblib`. Esto hace que el flujo sea reproducible y permite reutilizar los modelos sin tener que entrenarlos nuevamente.

Finalmente, el notebook entrena un modelo final univariante con toda la historia diaria disponible y genera un pronóstico para los próximos 7 días. Esta decisión es práctica porque el modelo univariante no depende de variables externas futuras. El pronóstico se guarda en `pronostico_proximos_7_dias.csv`, cerrando el proyecto con un flujo completo: preparación de datos, análisis exploratorio, entrenamiento, evaluación, comparación y predicción futura.

7. Conclusiones

El proyecto permitió construir un flujo completo de forecasting aplicado a datos de calidad del aire. Se partió de registros horarios, se creó una marca temporal, se transformó la información a frecuencia diaria y se respetó el orden cronológico en todas las etapas. También se decidió conservar todos los días calendario después del resampling para mantener la frecuencia diaria regular, documentando como limitación que algunos días tenían menos registros horarios.

El modelo base univariante sirvió como referencia inicial, pero el Grid Search mejoró el desempeño. El mejor modelo univariante utilizó 28 lags, 100 árboles, profundidad sin limitar y `min_samples_leaf` igual a 3. Este modelo redujo el error frente al modelo base, tanto en backtesting como en la evaluación final sobre los primeros 7 días de prueba. Por eso, se concluye que la selección de lags e hiperparámetros tuvo un impacto positivo en la capacidad predictiva.

La extensión con variables exógenas permitió analizar si sensores y variables ambientales podían aportar información adicional. Sin embargo, su uso operativo depende de conocer esas variables en el futuro. Por eso, el modelo exógeno es útil para comparación, mientras que el modelo univariante final es más práctico para generar pronósticos reales de 7 días.

En síntesis, el proyecto cumple con los pasos principales de una tarea de forecasting: preparación temporal, análisis exploratorio, modelo base, backtesting, Grid Search, comparación de modelos, guardado de resultados y generación de pronóstico. La principal fortaleza es que se respeta la estructura temporal de los datos. La principal limitación es que la concentración de benceno puede depender de factores externos difíciles de anticipar, por lo que una mejora futura sería incorporar información meteorológica futura o desarrollar modelos adicionales para predecir las variables exógenas.