

**Mini proyecto de Series Temporales y Pronóstico
Forecasting de concentración diaria de benceno**

Grupo 6 - Estados Unidos | Aprendizaje Automático II

Licenciatura en Ingeniería de Datos e Inteligencia Artificial

Gael Paulo y Bruno del Valle

1. Introducción y planteamiento del problema

El objetivo de este proyecto es construir un flujo reproducible de forecasting para estimar la concentración diaria de benceno a partir de registros históricos de calidad del aire. El problema se plantea como una tarea de predicción temporal, donde el orden cronológico de las observaciones es fundamental para evitar errores metodológicos y obtener una evaluación realista del modelo.

La variable temporal se obtiene combinando las columnas fecha y hora, mientras que la variable objetivo es `concentracion_benceno`. Aunque el dataset original tiene frecuencia horaria, la frecuencia de trabajo definida para el proyecto es diaria. Por ese motivo, los registros horarios se agregaron mediante promedio diario. El horizonte de predicción establecido es de 7 días, por lo que el modelo debe estimar la concentración de benceno para la semana siguiente a partir de la información histórica disponible.

2. Descripción del dataset

El dataset utilizado corresponde a registros de calidad del aire tomados en una estación de monitoreo. Además de la concentración de benceno, el archivo contiene señales de sensores asociados a distintos contaminantes y variables ambientales, como temperatura, humedad relativa y humedad absoluta. Estas variables pueden ser útiles como posibles variables exógenas en una extensión multivariante, aunque el modelo final desarrollado en este informe se centra en un enfoque univariante.

El archivo utilizado fue `air_quality_docente.csv`. La variable temporal se construyó a partir de fecha y hora, la variable objetivo fue `concentracion_benceno`, la frecuencia original fue horaria, la frecuencia de trabajo fue diaria y el horizonte de predicción fue de 7 días. La partición inicial se realizó respetando el orden cronológico de la serie: se utilizó el 80% inicial de los registros para entrenamiento y el 20% final para prueba. El conjunto horario de entrenamiento abarcó desde el 10 de marzo de 2004 a las 18:00 hasta el 16 de enero de 2005 a las 15:00, con 7486 registros. El conjunto de prueba abarcó desde el 16 de enero de 2005 a las 16:00 hasta el 4 de abril de 2005 a las 14:00, con 1871 registros.

Luego del resampling diario, se revisó la cantidad de registros horarios por día. Para el entrenamiento se conservaron únicamente los días completos de 24 registros, ya que los promedios de días incompletos pueden ser menos representativos. Con esta decisión, la serie diaria de entrenamiento quedó formada por 304 observaciones, desde el 11 de marzo de 2004 hasta el 15 de enero de 2005.

3. Metodología

La preparación temporal siguió una secuencia ordenada: carga del archivo, creación de la marca temporal, ordenamiento cronológico, definición del índice temporal, transformación de frecuencia horaria a diaria y revisión de valores faltantes. En la serie diaria final de entrenamiento no se detectaron valores nulos en la variable objetivo.

Durante el análisis exploratorio se observó que la concentración diaria de benceno presenta variabilidad importante. La media de entrenamiento fue de 10.6766, con un desvío estándar

de 4.2401, un mínimo de 1.4312, una mediana de 10.7211 y un máximo de 24.3959. Mediante el criterio IQR se identificaron cuatro posibles valores atípicos altos, todos superiores al límite superior de 22.8754. Estos valores no fueron eliminados, ya que en un problema de calidad del aire pueden representar episodios reales de mayor contaminación y no necesariamente errores de medición.

Para el modelado se utilizó skforecast con una estrategia recursiva. Esta estrategia entrena un regresor supervisado usando valores rezagados de la propia serie y genera predicciones futuras reutilizando predicciones previas cuando se avanza más de un paso. Como modelo base se utilizó ForecasterRecursive con RandomForestRegressor y 7 lags, debido a que la serie es diaria y el horizonte del proyecto es semanal.

La evaluación formal se realizó mediante backtesting temporal con cortes sucesivos, horizonte de 7 pasos, ventana expansiva y reentrenamiento en cada corte. Esta decisión permite evaluar el modelo respetando el orden temporal de los datos, evitando particiones aleatorias que no serían adecuadas para una serie temporal. Después del modelo base se aplicó Grid Search sobre la cantidad de lags y algunos hiperparámetros del Random Forest. Las ventanas probadas fueron 7, 14, 21 y 28 lags. La selección del mejor modelo se realizó principalmente con MAE, complementando el análisis con RMSE.

4. Resultados y discusión

El modelo base permitió establecer una referencia inicial. En la evaluación puntual sobre los primeros 7 días del conjunto de prueba obtuvo un MAE de 4.6276 y un RMSE de 5.3128. En el backtesting interno, el modelo base obtuvo un MAE de 4.6100 y un RMSE de 5.9533. Estos valores sirvieron como punto de comparación para evaluar si el ajuste posterior realmente mejoraba el desempeño.

El Grid Search mostró una mejora respecto al modelo base. La mejor configuración encontrada fue un ForecasterRecursive con RandomForestRegressor, 28 lags, 100 árboles, profundidad sin limitar y min_samples_leaf = 3. Esta configuración obtuvo un MAE de 4.3649 y un RMSE de 5.5842 en la validación temporal interna. La mejora es razonable porque el uso de 28 lags permite que el modelo observe una ventana temporal más amplia, equivalente a varias semanas anteriores. Además, el valor de min_samples_leaf = 3 introduce una regularización sencilla, reduciendo el riesgo de que el modelo se ajuste demasiado a variaciones puntuales de la serie.

En la evaluación final sobre los primeros 7 días del conjunto de prueba, el mejor modelo univariante alcanzó un MAE de 3.6022 y un RMSE de 4.2168. Esto indica que el error absoluto promedio fue menor que el obtenido por el modelo base en el mismo horizonte. El hecho de que el RMSE sea mayor que el MAE muestra que todavía existen algunos errores relativamente grandes, algo esperable en una serie ambiental con variabilidad diaria y posibles episodios de contaminación más intensos.

En términos prácticos, el modelo ajustado representa una mejora frente al modelo base. Sin embargo, no debe interpretarse como una solución perfecta. La calidad del aire depende de múltiples factores externos, como condiciones meteorológicas, actividad urbana, emisiones y comportamiento de otros contaminantes. Un modelo puramente univariante solo utiliza la

historia pasada de la concentración de benceno, por lo que puede capturar patrones temporales, pero no explicar completamente cambios repentinos asociados a causas externas.

5. Conclusiones

El proyecto permitió construir un flujo completo y reproducible de forecasting aplicado a una serie temporal de calidad del aire. Se partió de datos horarios, se construyó una marca temporal, se respetó el orden cronológico, se transformó la información a frecuencia diaria y se entrenaron modelos orientados a predecir la concentración de benceno para un horizonte de 7 días.

El mejor resultado se obtuvo con el modelo univariante ajustado mediante Grid Search. La configuración seleccionada utilizó 28 lags, 100 árboles, profundidad sin limitar y `min_samples_leaf = 3`. Este modelo logró reducir el MAE frente al modelo base, tanto en la validación temporal interna como en la evaluación final sobre el horizonte de prueba. Por lo tanto, la selección de lags e hiperparámetros tuvo un impacto positivo en la capacidad predictiva.

Como principal limitación, el modelo final utiliza únicamente información histórica de la variable objetivo. Esto lo hace práctico para generar pronósticos, porque no depende de conocer variables futuras, pero también limita su capacidad para explicar cambios asociados a factores ambientales o sensores externos. Como trabajo futuro, sería conveniente desarrollar y comparar un modelo con variables exógenas, incorporando sensores y variables meteorológicas, siempre considerando que para usarlo operativamente sería necesario disponer de esas variables para los días futuros.

6. Referencias

Para el desarrollo de este informe se utilizó el material de clase de Aprendizaje Automático II correspondiente a la unidad de Series Temporales y Pronóstico, el dataset Air Quality en su versión docente adaptada, la documentación oficial de `skforecast` y la documentación oficial de `scikit-learn`.